

구간을 어떻게 자를 것인가, 그리고 최종 모델

마커 기반과 지형지물 기반의 전면 비교 · 14 개 조합 학습 결과 · 작성 2026-09-01

요약

레이더 신호에서 호흡수를 추정할 때, 구간을 어떤 기준으로 자르는지가 어떤 모델을 쓰는지보다 결과를 크게 좌우한다는 것을 확인했습니다. 두 가지 자르기 방식과 여섯 가지 모델을 교차해 14 개 조합을 같은 조건에서 학습했습니다.

	MAE (회/분)	1 회/분 이내	비고
마커 기반 · 최고	1.58	80%	SNN direct
지형지물 기반 · 최고	1.18	89%	SNN delta — 최종 채택
고전 신호처리 (학습 없음)	1.61	79%	지형지물 기준
ANN	1.53	86%	파라미터 17,377
SNN	1.18	89%	파라미터 7,971 — 절반 이하

세 줄 결론

1. 지형지물로 자르면 어떤 방법을 써도 1.18~1.61, 마커로 자르면 1.58~1.96 — 자르기의 효과가 모델의 효과보다 큼니다.
2. SNN 이 ANN 을 앞섭니다 (1.18 vs 1.53). 파라미터는 절반 이하입니다.
3. 두 자르기 방식은 서로 5 초 안에서 일치합니다 — 팀의 마커 작업이 틀렸던 것이 아니라, 두 방식이 서로를 확인해 줍니다.

1. 왜 이 비교가 필요했나

BIOPAC 호흡 벨트의 라벨을 레이더 신호에 옮기려면 두 장비의 시각 차를 알아야 합니다. 실험 중 손으로 누른 마커가 그 역할을 하도록 되어 있었지만, 실제 데이터에서는 마커 개수가 **피험자마다 5 개에서 48 개까지** 제각각이었습니다 (기대 20~22 개).

"3 번째 마커가 실험 2 시작"과 같은 규칙이 성립하지 않는다는 뜻입니다.

대안 — 지형지물(地形地物) 기반. 시각 차를 구하는 대신, 레이더가 직접 보는 사건을 찾아 그것을 기준으로 삼습니다. 지도 없이 산에서 위치를 잡을 때 봉우리나 강줄기를 쓰는 것과 같은 방식입니다.

실험	레이더가 보는 사건	검출 근거
실험 1	몸을 돌릴 때 생기는 움직임 봉우리 2 개	28 명에서 61.0~63.3 초 간격으로 일관
실험 2	숨 참는 30 초 동안의 호흡 진폭 붕괴	25 명 전원 기준선의 3~13%(중앙값 7%)로 붕괴

설계상의 함정 하나

시작마커 · 회전 1 · 회전 2 · 종료마커가 모두 약 62 초 간격이라, 아무 쌍이나 잡으면 역할이 한 칸씩 밀립니다.

"회전 1 은 녹화 후 50~120 초"라는 제약을 넣자 잘못 잡힌 4 명이 모두 교정됐습니다.

2. 두 방식의 전면 비교

공정한 비교를 위해 **이전 세션에서 팀과 함께 만든 HAI_동기화_종합.xlsx**의 실험 2 구간(레이더 시간)을 마커 기준으로 삼았습니다. 자르기 외의 조건 — 신호 처리, 창 길이, 추정기 — 은 모두 동일합니다.

2.1 성능

	MAE (회/분)	1 회/분 이내	사용 가능
마커 기반	1.78	74%	21 명 · 588 창
지형지물 기반	1.33	82%	28 명 · 784 창

공통 21 명 기준입니다. 21 명 중 **13 명**에서 지형지물이 낮습니다. 구간별로 보면 평소 호흡에서 차이가 가장 크고 (2.24 vs 0.65), **회복 호흡에서는 오히려 마커가 낮습니다** — 한쪽이 전부 이기는 것은 아닙니다.

커버리지 차이도 큼니다. 마커 방식으로는 **7 명이 경계 미검출로 아예 사용 불가**입니다. 지형지물 기반은 S01(본 녹화 12.5 초)을 제외한 28 명 전원을 씁니다.

2.2 두 방식은 서로를 확장한다

"몇 번째 마커"가 아니라 "가장 가까운 마커"로 대조하면 21 명이 5 초 안에서 일치합니다.

기준점	평균 차	표준편차	판정
실험 1 시작	+4.8 초	3.3 초	일치
실험 1 종료	-5.2 초	3.4 초	일치
실험 2 시작	+4.1 초	3.4 초	일치

계통적으로 몇 초 어긋나는 것은 **정의의 차이**입니다 — 마커는 실험을 시작하는 순간 누른 것이고, 우리 블록은 회전 봉우리를 기준으로 잡습니다. **팀의 마커 작업이 틀렸던 것이 아닙니다.**

2.3 동기 오차가 결과를 얼마나 오염시키나

인위적으로 시차를 넣어 재봤습니다.

넣은 시차	0 초	2 초	5 초	10 초	20 초
MAE (회/분)	1.55	1.66	1.98	2.74	4.72

우리 동기 정밀도는 중앙값 1.1 초(σ 4.5 초)입니다. **호흡수 추정에는 충분**하지만, 마커 기반이 가질 뻔했던 ± 20 초 오차였다면 치명적이었을 것입니다.

결정

지형지물로 자르고, 마커로 검증하고, 안 맞는 사람을 걸러낸다.

피험자별 전체 구간표와 마커와의 시차는 실험비교_마커 vs 지형지물.xlsx 의 1_구간표 시트에 있습니다.

3. 방법론 오류와 교정

학습 코드를 확인한 결과, 매 에폭마다 **평가 폴드**에서 성능을 재고 그중 최고를 결과로 채택하고 있었습니다. 이는 early stopping 이 아니라 **평가셋으로 에폭을 고르는 것**이며, 결과가 부풀려집니다.

	부풀려진 값	교정 후	차이
마커 · ANN	1.53	1.77	+0.24
지형지물 · ANN	1.24	1.53	+0.29
지형지물 · SNN 최고	1.13	1.18	+0.05

부풀림이 조건마다 다릅니다. 그래서 "비교는 어차피 공정하니 괜찮다"고 넘길 수 없었습니다. 실제로 **결론이 바뀌었습니다** — 이전에는 ANN 과 SNN 이 거의 같아 보였는데(1.24 vs 1.13), 교정 후에는 SNN 이 확실히 앞섭니다.

교정한 절차

	설정	왜
분할	시험자 단위 학습/검증/평가 3 분할	평가 폴드 f, 검증 폴드 (f+1)%4, 나머지 학습
에폭	상한 60, 인내 10 조기종료	사람이 에폭을 정하지 않고 데이터가 정하게
모델 선택	검증셋 최고 에폭의 가중치 복원	평가셋은 마지막에 한 번만 사용
교차검증	시험자 분리 4-fold	같은 사람의 창이 학습·평가에 함께 들어가면 누수

4. 최종 14 개 조합

자르기 2 방식 × (고전 신호처리 + ANN + SNN 인코딩 5 종). 두 조건 외에는 층 구조, 폭, 학습률, 배치, 손실, 시드를 모두 고정했습니다.


자르기	모델	인코딩	MAE	1 회/분	파라미터	조기종료 에폭
마커	고전 신호처리	—	1.86	73%	0	—
마커	ANN	—	1.77	79%	17,377	2, 4, 2, 14
마커	SNN	rate	1.89	78%	7,971	2, 13, 26, 35
마커	SNN	step-forward	1.91	79%	7,971	4, 10, 9, 13
마커	SNN	population	1.96	79%	8,259	2, 14, 2, 16
마커	SNN	delta	1.69	80%	7,971	20, 10, 10, 19
마커	SNN	direct	1.58	80%	7,875	10, 2, 40, 16
지형지물	고전 신호처리	—	1.61	79%	0	—
지형지물	ANN	—	1.53	86%	17,377	13, 18, 9, 1
지형지물	SNN	rate	1.24	88%	7,971	19, 29, 16, 54
지형지물	SNN	step-forward	1.23	89%	7,971	14, 24, 36, 3
지형지물	SNN	population	1.31	87%	8,259	9, 10, 5, 3
지형지물	SNN	delta	1.18	89%	7,971	18, 22, 34, 4
지형지물	SNN	direct	1.41	86%	7,875	21, 32, 2, 1

최종 결과 — 지형지물 자르기 + SNN(delta)에서 1.18 회/분

학습/검증/평가 3분할 · 피험자 분리 4-fold · 검증셋 기준 조기종료(인내 10, 상한 60에폭) · 평가셋은 마지막에 한 번만 확인


A. 14개 조합 전체 — 자르기 2방식 × (고전 + ANN + SNN 5인코딩)

주황=마커 기반, 파랑=지형지물 기반, 회색=학습 없는 고전 기준선, 초록=최고 성능




B. 자르기가 모델보다 크게 좌우합니다

같은 방식 안에서 모델을 바꾼 폭(0.35)보다 자르기를 바꾼 폭(0.48)이 더 큼니다



C. 학습이 언제 멈췄는가

검증셋이 좋아지기를 멈춘 에폭 (4폴드 각각) · 가로줄은 평균 · 성적 좋은 인코딩일수록 오래 학습됩니다



14 개 조합 전체 순위, 자르기 효과와 모델 효과의 비교, 조기종료 에폭 분포


읽어야 할 것 세 가지

1. 자르는 방식이 모델보다 중요하다. 지형지물 안에서 모델을 바꿔 얻은 폭은 0.35 인데, 자르기를 바꿔 얻은 폭은 0.48 입니다. 전처리와 라벨 품질이 모델 선택보다 큰 영향을 준다는, 흔하지만 자주 무시되는 사실의 사례입니다.

2. SNN 이 ANN 을 이긴다 — 파라미터는 절반 이하로. 1.18 vs 1.53, 7,971 vs 17,377. 조기종료 에폭을 보면 ANN 은 평균 10.3 에폭에서 멈추고 성적 상위 인코딩은 delta 19.5, rate 29.5 까지 갑니다. ANN 이 더 빨리 과적합합니다. 다만 population 은 평균 6.8 에폭으로 더 일찍 멈추면서 성능은 ANN 보다 좋습니다 — **"오래 학습되면 좋다"**는 단순 대응은 성립하지 않습니다.

3. 인코딩 순위가 자르는 방식에 따라 뒤집힌다. 마커 기반에서는 direct 가 최고, 지형지물에서는 delta 가 최고입니다. 앞선 분류 과제(각도·호흡상태)에서는 두 과제 모두 rate 가 1 위로 순위가 같았는데, 이 회귀 과제에서는 유지되지 않습니다. 인코딩 선택에 하나의 정답은 없습니다.

5. 잘 맞는 파형과 안 맞는 파형



위 3명은 오차 0.06~0.10 회/분, 아래 3명은 3.17~6.96 회/분

주목할 점은 못 맞힌 경우에도 파형 자체는 따라간다는 것입니다(상관 0.62~0.86). 무너지는 지점은 파형 복원이 아니라 **호흡수 추출**입니다 — 체동이 섞여 스펙트럼에 봉우리가 두 개 생기면 엉뚱한 쪽을 고릅니다.

별도로 시도한 end-to-end 학습(신호에서 호흡수를 직접 출력)의 결과도 같은 방향을 가리킵니다.

조건	창	MAE	1 회/분 이내
아무것도 학습 안 하고 평균만 답하기	784	5.87	11%
호흡수 직접 예측	784	5.26	15%
호흡수 직접 예측 (데이터 5 배)	3,696	5.03	19%
파형 출력 (위상 둔감 손실)	3,696	6.42	41%
고전 신호처리	3,696	1.55	80%

창을 5 배로 늘려도 5.26 → 5.03 으로 제자리입니다 — **표본 수가 아니라 정보량의 문제**입니다. 반면 정답을 숫자 1 개에서 파형 100 개로 늘리자 1 회/분 이내가 19% → 41%로 두 배가 됐습니다. **정답 밀도가 학습을 좌우합니다.**

참고 — MoRe-Fi (SenSys 2021)와의 규모 차이

논문: 12 명 · 66 시간 · 학습 8,000 쌍 · 파라미터 2,360 만 · 파형 코사인 유사도 0.9162

우리: 앉아서 호흡한 구간 약 2 시간 · 590~3,700 창 · 파라미터 8 천 · 파형 상관 0.456

end-to-end 가 실패한 이유가 여기 있습니다. 나머지 30 명 데이터가 온 뒤에 다시 시도할 사안입니다.

6. 아직 근거가 없는 설정

아래 세 가지는 검증셋 기준으로 탐색해야 제대로 된 설정이 됩니다. 현재는 임의로 정한 값입니다.

설정	값	상태
은닉층 크기	96 → 48, 2 층	탐색 안 함. 데이터 규모를 보고 임의로 정함
보조 특징 구성	13 종	어느 것이 실제로 기여하는지 미확인
손실 가중	회귀 : 순위 = 1 : 0.5	탐색 안 함

나머지 설정의 근거는 **실험비교_마커 vs 지형지물.xlsx**의 **5_판단근거** 시트에 설정 19 개 각각에 대해 "표준인지 우리가 정한 것인지"까지 적어 두었습니다.

회의에서 확인·요청할 것

항목	내용
공통 트리거	다음 촬영 시 레이다·BIOPAC 을 동시에 시작시키는 신호. 있으면 이 문서의 1~2 장 전체가 불필요해집니다
환경 파일	빈 방 1 분 녹화가 전달된 30 명 폴더에 없습니다. 되먹임 필터로 대체했으나 실제 참조가 더 정확합니다
S01_CMS 재촬영	본 녹화가 12.5 초(501 프레임)뿐입니다
파싱 수정본 공유	sync_tool_S02.m 190 번 줄이 인터리브 방식입니다. 선배 쪽 파형 복원도 같은 영향을 받을 수 있습니다

상세 기록은 저장소의 docs/uwb-snn-2026-09-01/ 에 있습니다. 실험 16 개가 각각 폴더 하나로 정리되어 있습니다.

이덕원 · 2026-09-01 · \$4